

面向长上下文建模的量化索引残差动态记忆机制研究

论文关键词：长上下文建模、高效序列模型、量化索引、残差动态记忆、信息保持与检索

一、课题来源及研究的目的和意义

1.1 课题来源

本课题来源于导师指导下的长上下文语言模型与高效序列建模研究方向，并由本人结合相关文献调研和前期原型探索进一步凝练形成。长上下文建模在长文档问答、代码理解、检索增强生成和长对话建模等场景中具有重要应用价值。这类任务不仅要求模型处理更长输入，还要求模型能够保持并检索前文中的实体关系、变量绑定、局部事实和上下文约束等关键信息。

标准 Transformer 的全注意力机制虽然信息访问能力强，但在长序列场景下计算和显存开销较高。现有线性注意力、状态空间模型和门控循环模型等方法通过有限状态或压缩注意力降低成本，但在高负载长上下文中仍可能出现记忆冲突、信息遗忘和读出误差。因此，本课题拟研究一种量化索引残差动态记忆机制，探索如何在高效序列模型中更有效地组织、校正与利用历史信息，从而提升长上下文建模中的信息保持与检索能力。

1.2 研究目的

本课题旨在面向长上下文建模场景，探索一种在计算成本可控条件下提升模型历史信息保持与检索能力的动态记忆机制。研究重点是缓解高效序列模型在压缩长上下文信息时容易出现的记忆冲突、信息遗忘和读出误差等问题，使模型能够在较长输入中更稳定地利用前文信息。

本研究希望通过对量化索引残差动态记忆机制的设计与实验验证，回答三个核心问题：

- 量化索引是否能够更有效地组织长上下文中的历史信息；
- 残差动态记忆是否能够补偿粗粒度量化记忆带来的读出误差；
- 该机制在可控任务和自然语言长上下文场景中是否具有稳定效果和工程可行性。

最终目标是形成一种结构清晰、可实验验证、能够与现有高效序列模型进行系统对比的长上下文动态记忆建模方法。

1.3 研究意义

本课题具有一定的理论研究意义和工程应用价值。理论上，长上下文建模的关键不仅是扩展输入长度，还包括如何在有限计算成本下有效保持、组织和读取历史信息。现有高效序列模型虽然能够降低长序列计算开销，但由于通常需要将历史信息压缩到有限状态中，容易出现记忆冲突、信息遗忘和读出误差。本课题的特色在于将量化索引用于长上下文动态记忆的分槽组织，并进一步引入残差动态记忆对粗粒度量化记忆的读出误差进行校正。该思路不是单纯压缩注意力或扩大记忆容量，而是关注历史信息在有限状态中的组织、冲突缓解与误差补偿，为高效序列模型提升长上下文信息保持与检索能力提供新的机制设计思路。

工程应用上，长上下文能力直接影响长文档问答、代码理解、检索增强生成、长对话建模和专业文档分析等实际任务的效果。如果模型能够在较低计算和显存成本下更稳定地利用

量化索引残差动态记忆

JW

Jian Wang 昨天 21:12

这里术语有点堆叠，而且出得太快，前面没有任何铺垫，很难让人理解什么是“量化索引残差动态记忆”？

通过对量化索引残差动态记忆机制的设计...

JW

Jian Wang 昨天 21:19 (编辑过)

这句话有些疑问，量化索引残差动态记忆是提出的新机制吗？还是已有的方法？如果是新的机制，就不应该用通过 xxxxx 这种表述

量化索引是否能够更有效地组织长上下文...

JW

Jian Wang 昨天 21:22

- 这三个研究问题应该是让人直观易懂的，尽量不要用过于术语的表达，否则在缺少铺垫的情况下，别人还没理解什么是“量化索引”和“残差动态记忆”，就更难理解整个问题了；
- 三个研究问题之间的关联性感觉不够连贯，e.g., 递进关系？并列关系？这是大家最容易问到的

前文信息，将有助于提升长文本处理系统的效率和可用性。因此，本课题对低成本长上下文语言模型设计、动态记忆机制优化以及相关自然语言处理应用具有一定参考价值。

二、国内外研究现状评述及存在问题分析

2.1 国内外研究现状评述

近年来，长上下文建模逐渐成为语言模型研究中的重要方向。标准 Transformer 依靠全注意力机制显式访问上下文中的所有历史 token，在长文本理解、信息检索和上下文依赖建模中表现较强，但其计算和显存开销会随序列长度增加而快速增长。因此，如何在降低长序列计算成本的同时保持较强建模能力，成为高效序列模型研究的核心问题。

为解决全注意力的高开销问题，研究者提出了线性注意力、状态空间模型和门控循环模型等高效序列建模方法。Katharopoulos 等人在 ICML 2020 提出的 Linear Transformer 将自回归注意力改写为线性递推形式，使模型能够用有限矩阵状态压缩历史信息；Schlag 等人在 ICML 2021 从 fast-weight 视角进一步指出，线性注意力可以理解为一种动态更新临时矩阵记忆的快权重模型。

状态空间模型方面，Gu 和 Dao 在 2023/2024 年提出的 Mamba 通过选择性状态空间机制增强模型对输入内容的选择能力；Dao 和 Gu 在 2024 年提出的 Mamba2 / SSD 框架进一步将状态空间模型与注意力形式联系起来，提升了效率和可扩展性。

在动态记忆更新方面，GLA、DeltaNet 和 GDN 等方法具有代表性。Yang 等人在 ICML 2024 提出的 GLA 在矩阵状态中加入数据相关门控，使模型能够动态控制历史信息的保留程度；Yang 等人在 NeurIPS 2024 提出的 DeltaNet 使用 delta rule 对已有 key-value 记忆进行定向更新，缓解普通线性注意力只累加、不精确改写的问题；Yang、Kautz 和 Hatamizadeh 在 ICLR 2025 提出的 GDN 进一步结合门控和 delta rule，兼顾快速遗忘与精确记忆修改，是本课题最直接相关的高效动态记忆基线之一。

测试时记忆也是近年来长上下文建模中的重要方向。Sun 等人在 2024 年提出 TTT Layers，通过在测试序列上更新可学习的 hidden state 来增强上下文记忆；Behrouz、Zhong 和 Mirrokni 在 2025 年提出 Titans，引入 neural long-term memory 来存储更长期的历史信息。这类方法与本课题都关注动态记忆，但更侧重测试时学习和长期神经记忆；本课题则聚焦于前向建模过程中的量化索引分槽记忆与残差校正。

稀疏记忆模型通过大量稀疏记忆槽提升可访问记忆容量。Zhao 和 Jones 在 2026 年提出 FwPKM，利用 Product-Key 记忆表和局部梯度更新实现快速上下文记忆。与其不同，本课题不侧重大规模稀疏记忆表的动态重写，而关注量化索引下的分槽记忆组织与残差校正。

此外，向量量化为长上下文信息压缩与索引组织提供了重要思路。Lingle 在 ICLR 2024 提出的 Transformer-VQ 通过量化 key 和缓存机制实现线性时间的 dense self-attention；Liu 等人在 IJCAI 2024 提出的 LongVQ 则将 VQ 与 structured memory 结合，用固定长度 codebook 压缩全局信息。与这些方法不同，本课题不只关注量化压缩本身，而是研究如何在量化索引得到的记忆槽内引入残差动态记忆，对粗粒度量化读出误差和槽内冲突进行校正。

2.2 存在问题分析

现有研究虽然推动了长上下文高效建模，但仍存在以下问题。

- 有限状态容量容易导致记忆冲突。** 线性注意力、状态空间模型和门控循环模型通常需要将历史信息压缩到有限状态中。当上下文变长、关键信息增多时，不同信息可能发生混叠，造成信息遗忘和读出误差。

存在问题分析 现有研究虽然推动了长上…

JW Jian Wang 昨天 21:25
现有不足之处最好总结为 3 个点，这样后续的研究问题也是 3 个，前后保持呼应

2. **动态记忆的组织方式仍有改进空间。** GDN、DeltaNet、Mamba2 等方法通过门控、delta rule 或状态递推改善记忆更新，但多数仍主要依赖整体状态压缩历史信息，缺少显式的分槽组织机制。GDN 的工作也指出，线性 Transformer 在检索和长上下文任务中仍存在限制，需要更有效的记忆控制与更新机制。
3. **VQ 方法对槽内误差校正关注不足。** 现有 VQ 长序列方法更多关注 key 量化、缓存压缩或全局信息抽象，但多个 token 映射到同一码本槽后，仍可能产生槽内冲突和粗粒度读出误差。
4. **机制任务与自然语言任务之间仍有差距。** MQAR 适合分析模型的信息保持与检索机制；但真实长上下文能力还需要结合自然语言建模、长文档评估和公开长上下文任务进一步验证。Zoology 提出 MQAR 的动机之一，正是为了更贴近真实语言中的多查询信息回忆需求。

基于上述问题，本课题拟研究一种**量化索引残差动态记忆机制**，通过分槽组织历史信息，并利用残差动态记忆校正粗粒度量化记忆中的近似误差和槽内冲突，从而提升长上下文建模中的信息保持与检索能力。

三、课题主要研究内容和拟解决的关键问题

3.1 课题主要研究内容

本课题围绕长上下文建模中的历史信息保持与检索问题，研究一种**量化索引残差动态记忆机制**。主要研究内容包括以下几个方面。

1. **研究量化索引残差动态记忆机制。** 针对长上下文中历史信息数量多、容易混叠的问题，本文拟通过量化索引将历史信息组织到不同记忆槽中，形成分槽动态记忆结构；同时针对粗粒度量化记忆可能产生的近似误差和槽内冲突，引入残差动态记忆进行补偿和校正，从而提升模型对历史信息的保持、读取和利用能力。
2. **验证量化索引残差动态记忆机制的有效性。** 本文将围绕量化索引和残差动态记忆两个核心模块，分析其在不同上下文长度、信息负载和查询数量下对历史信息保持与检索能力的影响。通过 MQAR 等可控任务，验证该机制是否能够缓解有限状态下的记忆冲突和读出误差，并为后续自然语言长上下文实验提供机制依据。
3. **开展自然语言及长上下文验证。** 除 MQAR 等机制任务外，本文计划进一步在自然语言场景中验证方法的泛化能力。基础实验包括在 FineWeb-Edu 等语料上进行小规模语言建模训练，并在 PG-19 等长文档数据上评估困惑度、位置相关损失和远距离上下文利用情况。同时，本文将结合 AR-hit、重复 n-gram、实体回忆等文本切片，分析模型对历史信息的保持与检索能力。若实验条件允许，将进一步选取 RULER 或 LongBench 的部分代表性子任务进行补充评估，例如针中取证任务 NIAH、多 needle 检索、多跳追踪、单文档问答、多文档问答和代码补全等。
4. **开展公平基线对比和模块消融实验。** 本文将本方法与 GLA、DeltaNet、Gated DeltaNet、Mamba2、全注意力 Transformer 等模型进行对比；并通过去除残差动态记忆、仅保留粗粒度量化记忆、调整残差记忆容量和码本规模等实验，分析不同模块对模型效果的贡献。
5. **开展机制指标与效率分析。** 本文将通过记忆槽使用分布、残差注入强度、记忆状态范数和长上下文切片表现等指标，分析量化索引与残差动态记忆是否真正改善历史信息的组织、校正和读取能力；同时结合训练速度、显存占用和长度扩展表现，评估该机制的工程可行性。

3.2 拟解决的关键问题

本课题围绕长上下文建模中的历史信息保持与检索问题，拟重点解决以下关键问题。

拟解决的关键问题

JW Jian Wang 昨天 21:24
通常总结为三个关键问题，太多说明不够凝练，有些琐碎

实验路线图如下所示：

JW Jian Wang 昨天 21:30
这个图要画的总体研究路线图，而不只是实验路线，因此还需把前面的三个不足、对应的研究问题放进图里面来，然后才是方法/实验方案


1. 长上下文历史信息如何在有限状态中有效组织。现有高效序列模型通常需要将历史信息压缩到有限状态中，当上下文变长、关键信息增多时，容易出现信息混叠和记忆冲突。本文拟研究如何通过量化索引将历史信息划分到不同记忆槽中，从而提高有限状态下的信息组织能力。
2. 粗粒度量化记忆的读出误差如何校正。量化索引可以压缩并组织历史信息，但多个 token 被映射到同一记忆槽后，可能造成槽内冲突和粗粒度读出误差。本文拟研究如何利用残差动态记忆对这类误差进行补偿，提高模型对历史信息的读取准确性。
3. 如何区分方法机制优势与单纯容量优势。长上下文模型效果提升可能来自结构设计，也可能只是因为记忆容量更大。本文需要通过公平基线对比、动态容量控制和模块消融实验，分析量化索引、残差校正和记忆容量分别对模型效果的贡献。
4. 机制任务中的改进能否迁移到自然语言长上下文场景。MQAR 等任务适合分析模型的信息保持与检索机制，但不能完全代表真实自然语言任务。本文拟进一步在自然语言语言建模、长文档评估和文本切片分析中验证该机制是否具有泛化能力。
5. 该机制是否具备实际工程可行性。本课题不仅关注模型效果，还需要考虑训练速度、显存占用、不同序列长度下的运行表现和实现复杂度，评估量化索引残差动态记忆机制能否在实际长上下文建模中稳定使用。

四、拟采取的研究方法、研究方案及其可行性分析

4.1 总体研究路线

本课题拟采用“模型机制设计—可控任务验证—自然语言验证—机制与效率分析”的研究路线。首先围绕长上下文中历史信息压缩、记忆冲突和读出误差等问题，设计量化索引残差动态记忆机制；随后通过可控任务、自然语言任务、基线对比和消融实验验证方法有效性；最后结合机制指标和效率指标分析该方法的作用机制与工程可行性。

实验路线图如下所示：



第一，设计并实现量化索引残差动态记忆机制。

- 1. 本文拟构建一种“局部上下文建模 + 量化索引远程记忆 + 残差动态校正”的长上下文建模结构。模型首先将输入 token 投影为 query、key 和 value 表示，近邻上下文由局部注意力建模，远距离历史信息则通过量化索引记忆进行压缩存储与读取。
- 2. 模型维护一个可学习 codebook，每个 codeword 对应一个记忆槽中心；历史 token 的 key 根据与 codeword 的匹配关系被分配到不同记忆槽中，从而实现历史信息的分槽组织。在每个记忆槽内，模型维护粗粒度统计状态 $\mathcal{G}_s$ 和 $\mathcal{L}_s$ ，其中 $\mathcal{G}_s$ 表示该槽内 value 的加权累积， $\mathcal{L}_s$ 表示对应写入质量，粗粒度记忆读出为： $\mu_s = \frac{\mathcal{G}_s}{\mathcal{L}_s + \epsilon}$ 。
- 3. 由于多个 token 可能被聚合到同一记忆槽中，粗粒度读出可能存在近似误差和槽内冲突，因此本文进一步引入残差动态记忆，学习当前 value 与粗粒度读出之间的残差 $u_{t,s} = v_t - \text{sg}(\mu_{t,s}^{pre})$ 。具体而言，模型在每个记忆槽内维护低秩残差矩阵 M_s ：写入时根据 key 与 codeword 的差异构造写入地址，并以残差 $u_{t,s}$ 为目标对 M_s 进行 gated-delta 式的误差校正更新，即在遗忘旧残差状态的同时，根据当前残差预测误差对记忆矩阵进行定向修正。读出时根据 query 与 codeword 的差异构造读出地址，从 M_s 中读取残差校正项，用于补偿粗粒度量化记忆的读出误差。
- 4. 最终模型先得到局部上下文与粗粒度远程记忆形成的基础输出 o_t^{base} ，再注入残差校正项，得到 $o_t = o_t^{base} + \lambda_t \text{RMSNorm}(u_t^{res})$ 。
- 5. 该机制的核心定位是：量化索引用于分槽组织历史信息，粗粒度记忆用于低成本远程读出，残差动态记忆用于校正量化聚合带来的读出误差和槽内冲突。

第二，开展机制验证、基线对比与模块消融实验。

本文将以 MQAR 等任务作为可控验证场景，分析模型在不同上下文长度、信息负载和查询数量下的表现；同时将本方法与门控 Delta 网络、DeltaNet、Mamba2、门控线性注意力和全注意力 Transformer 等模型进行对比，并通过去除残差动态记忆、仅保留粗粒度量化记忆、调整码本规模和残差记忆容量等消融实验，分析量化索引、粗粒度记忆、残差校正和记忆容量对模型效果的贡献。

第三，开展自然语言及长上下文验证。

除 MQAR 等机制任务外，本文计划进一步在自然语言场景中验证方法的泛化能力。基础实验包括在 FineWeb-Edu 等语料上进行小规模语言建模训练，在 PG-19 等长文档数据上评估困惑度、位置相关损失和远距离上下文利用情况，并结合 AR-hit、重复 n-gram、实体回忆等文本切片分析模型的信息保持能力。若实验条件允许，将进一步选取 RULER 或 LongBench 的部分代表性子任务进行补充评估。

第四，开展机制指标与效率分析。

本文将通过记忆槽使用分布、残差注入强度、记忆状态范数、长上下文切片表现等指标，分析量化索引和残差动态记忆是否真正参与历史信息组织与校正；同时统计训练速度、显存占用和不同序列长度下的运行表现，评估该机制在实际训练中的工程可行性。


具体模型结构如下图所示：

具体模型结构如下图所示：

JW

Jian Wang 昨天 21:33

图中的标题要改为正常大小写，全大写 AI 味儿太明显了



4.3 可行性分析

从理论基础看，线性注意力、状态空间模型、门控 Delta 网络、Transformer-VQ、FwPKM 等相关工作已经表明，动态记忆、量化索引和高效长上下文建模具有明确研究价值。本课题在已有研究基础上进一步关注“量化索引分槽组织”和“残差动态校正”，研究目标较为清晰。

从工程基础看，前期已完成方法原型实现和初步测试，具备继续开展系统实验的基础。后续实验以小规模可控模型为主，通过统一训练预算、参数量、动态记忆容量和评估设置进行比较，整体实验规模可控。

从数据与评估条件看，MQAR 可用于机制验证，FineWeb-Edu、PG-19 等公开语料可用于自然语言训练和长文档评估，RULER、LongBench 等公开评测可作为补充验证。因此，本课题具备较明确的数据来源和评估路径。

从风险控制看，本课题可能面临自然语言训练成本较高、部分基线实现难度较大、机制任务结果无法完全迁移到真实文本等风险。对此，本文将采用分阶段实验策略：优先完成 MQAR、基线对比和消融实验，再开展小规模自然语言训练，最后根据实验条件选择部分公开长上下文任务进行补充评估，保证课题在毕业设计周期内可完成、可分析、可落地。

五、课题研究的特色与创新之处

本课题的特色与创新主要体现在：不将量化索引本身作为核心创新，而是进一步研究量化索引记忆槽内的残差动态校正机制。已有 VQ 长序列方法多侧重 key 量化、缓存压缩或全局信息压缩，而本文关注的是在量化索引得到的记忆槽中同时维护粗粒度记忆和残差动态记忆：粗粒度记忆用于低成本保存和读取历史信息的整体趋势，残差动态记忆用于补偿多个 token 聚合到同一记忆槽后产生的近似误差和槽内冲突。该机制将局部上下文建模、量化索引远程记忆、残差动态校正结合起来，重点提升高效序列模型在长上下文场景下对历史信息的保持、检索和利用能力。

六、计划进度和预期研究成果

6.1 计划进度

2026年5月—2026年7月：完成开题报告和文献调研，明确模型结构、实验任务和基线设置。

本课题的特色与创新主要体现在：不将量...

JW

Jian Wang 昨天 21:37

这种说法过于技术性偏细节，对于不是做这个方向的评委老师，可能根本感受不到特色之处，建议由小及大，说完细节之后要拔高。e.g., 对长下文建模的意义？这种方法能够提升模型部署的效率、节约 token 或时间开销？

在实验预研方面，已在 MQAR 等任务上...

2026年8月—2026年10月：完成模型原型、MQAR 实验、基线对比和模块消融。

2026年11月—2027年1月：开展自然语言建模和长文档验证实验。

2027年2月—2027年5月：整理实验结果，完成论文撰写、修改、送审和答辩准备。

6.2 预期研究成果

发明专利一项、会议论文一篇、GitHub 开源代码、Hugging Face 开源权重、学位论文。

七、前期预研工作基础

前期已围绕长上下文建模、高效序列模型、动态记忆机制和量化索引方法开展了较系统的文献调研，重点学习了 Linear Transformer、Mamba/Mamba2、GLA、DeltaNet、GDN、Transformer-VQ、LongVQ、TTT、Titans、FwPKM 等相关工作，初步明确了本课题与现有方法的关系和差异。

在方法设计方面，已完成量化索引残差动态记忆机制的初步方案设计，明确了局部上下文建模 + 量化索引远程记忆 + 残差动态校正的整体结构。前期原型中已包含量化路由、粗粒度记忆状态、残差动态记忆状态、残差写入、残差读出和输出融合等核心模块，为后续系统实验提供了工程基础。

在实验预研方面，已在 MQAR 等任务上进行了初步验证，观察到量化索引和残差动态记忆对长上下文信息保持与检索具有一定潜力。同时，前期也初步分析了模型容量、记忆槽规模、残差记忆容量、训练稳定性和不同随机种子结果波动等问题，为后续公平基线对比和消融实验提供了参考。

目前课题已具备继续推进的基础，但自然语言建模训练、长文档评估、公开长上下文任务测试、完整基线对比和开源权重整理仍属于后续工作。后续将基于已有原型和初步实验结果，进一步完善模型结构、补充实验验证。

八、涉及实验项目的安全风险分析与防控

本课题主要开展计算机模型训练、数据处理和算法实验，不涉及化学、生物、动物、人体或临床实验，整体安全风险较低。主要风险包括服务器长时间运行导致的设备过热、进程异常、数据误删、结果覆盖、账号密钥泄露和公开数据合规问题；实验过程中将通过设备监控、版本管理、结果备份、密钥保护和使用合规公开数据等方式进行防控。

九、主要参考文献

[1] VASWANI A, SHAZEER N, PARMAR N, 等. Attention is All you Need[C/OL]//Advances in Neural Information Processing Systems: 卷 30. Curran Associates, Inc., 2017[2026-05-22].
https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html.

[2] ZHAO T, JONES L. Fast-weight Product Key Memory[J]. arXiv preprint arXiv:2601.00671, 2026.

[3] YANG S, KAUTZ J, HATAMIZADEH A. Gated Delta Networks: Improving Mamba2 with Delta Rule[C/OL]//YUE Y, GARG A, PENG N, 等. International Conference on Learning Representations: 卷 2025. 2025: 29687-29707.
https://proceedings.iclr.cc/paper_files/paper/2025/file/4904fad153f6434a7bcf04465d4be2cc-Paper-Conference.pdf.

[4] YANG S, WANG B, SHEN Y, 等. Gated Linear Attention Transformers with Hardware-Efficient Training[C/OL]//SALAKHUTDINOV R, KOLTER Z, HELLER K, 等.

JW

Jian Wang 昨天 21:39 (编辑过)

这里可以适当给出一些初步的实验结果，用数据说说话，提升工作基础和可行性

- Proceedings of the 41st International Conference on Machine Learning: 卷 235. PMLR, 2024: 56501-56523. <https://proceedings.mlr.press/v235/yang24ab.html>.
- [5] SUN Y, LI X, DALAL K, 等. Learning to (Learn at Test Time): RNNs with Expressive Hidden States[C/OL]//Proceedings of the 42nd International Conference on Machine Learning. PMLR, 2025: 57503-57522[2026-05-22]. <https://proceedings.mlr.press/v267/sun25h.html>.
- [6] SCHLAG I, IRIE K, SCHMIDHUBER J. Linear Transformers Are Secretly Fast Weight Programmers[C/OL]//Proceedings of the 38th International Conference on Machine Learning. PMLR, 2021: 9355-9366[2026-05-22]. <https://proceedings.mlr.press/v139/schlag21a.html>.
- [7] LIU Z, WANG L, LI S, 等. LongVQ: long sequence modeling with vector quantization on structured memory[C/OL]//Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence. 2024. <https://doi.org/10.24963/ijcai.2024/510>. DOI:10.24963/ijcai.2024/510.
- [8] GU A, DAO T. Mamba: Linear-Time Sequence Modeling with Selective State Spaces[C/OL]//First Conference on Language Modeling. 2024. <https://openreview.net/forum?id=tEYskw1VY2>.
- [9] YANG S, WANG B, ZHANG Y, 等. Parallelizing Linear Transformers with the Delta Rule over Sequence Length[C/OL]//GLOBERSON A, MACKEY L, BELGRAVE D, 等. Advances in Neural Information Processing Systems: 卷 37. Curran Associates, Inc., 2024: 115491-115522. https://proceedings.neurips.cc/paper_files/paper/2024/file/d13a3eae72366e61dfdc7eea82eeb685-Paper-Conference.pdf. DOI:10.52202/079017-3668.
- [10] HSIEH C P, SUN S, KRIMAN S, 等. RULER: What' s the Real Context Size of Your Long-Context Language Models?[C/OL]//First Conference on Language Modeling. 2024. <https://openreview.net/forum?id=kloBbc76Sy>.
- [11] BEHROUZ A, ZHONG P, MIRROKNI V. Titans: Learning to Memorize at Test Time[C/OL]//BELGRAVE D, ZHANG C, LIN H, 等. Advances in Neural Information Processing Systems: 卷 38. Curran Associates, Inc., 2025: 113506-113543. https://proceedings.neurips.cc/paper_files/paper/2025/file/a4ca07aa108036f80cbb5b82285fd4b1-Paper-Conference.pdf.
- [12] LINGLE L D. Transformer-VQ: Linear-Time Transformers via Vector Quantization[C/OL]//KIM B, YUE Y, CHAUDHURI S, 等. International Conference on Learning Representations: 卷 2024. 2024: 6121-6150. https://proceedings.iclr.cc/paper_files/paper/2024/file/18eb80b9faaed5d003b31574bd2a3e9d-Paper-Conference.pdf.
- [13] KATHAROPOULOS A, VYAS A, PAPPAS N, 等. Transformers are RNNs: Fast Autoregressive Transformers with Linear Attention[C/OL]//Proceedings of the 37th International Conference on Machine Learning. PMLR, 2020: 5156-5165[2026-05-22]. <https://proceedings.mlr.press/v119/katharopoulos20a.html>.
- [14] DAO T, GU A. Transformers are SSMs: Generalized Models and Efficient Algorithms Through Structured State Space Duality[J]. Proceedings of Machine Learning Research, 2024, 235: 10041-10071.
- [15] ARORA S, EYUBOGLU S, TIMALSINA A, 等. Zoology: Measuring and Improving Recall in Efficient Language Models[C/OL]//KIM B, YUE Y, CHAUDHURI S, 等. International Conference on Learning Representations: 卷 2024. 2024: 15664-15730. https://proceedings.iclr.cc/paper_files/paper/2024/file/448fc91f669c15d10364ee01d512cc10-Paper-Conference.pdf.